Università degli Studi di Palermo

dipartimento di ingegneria unipa

Tipologie di Dato

INTELLIGENZA ARTIFICIALE PER L'INGEGNERIA BIOMEDICA (EX ROBOTICA MEDICA)

a.a. 2025/2026

Prof. Roberto Pirrone

LABORATORIO DI INTERAZIONE UOMO-MACCHINA
CHILAB

Sommario

- Pipeline dati e ETL
- Tipologie generali di analisi dei dati
- Principali tipi di dati

Pipeline dati e ETL

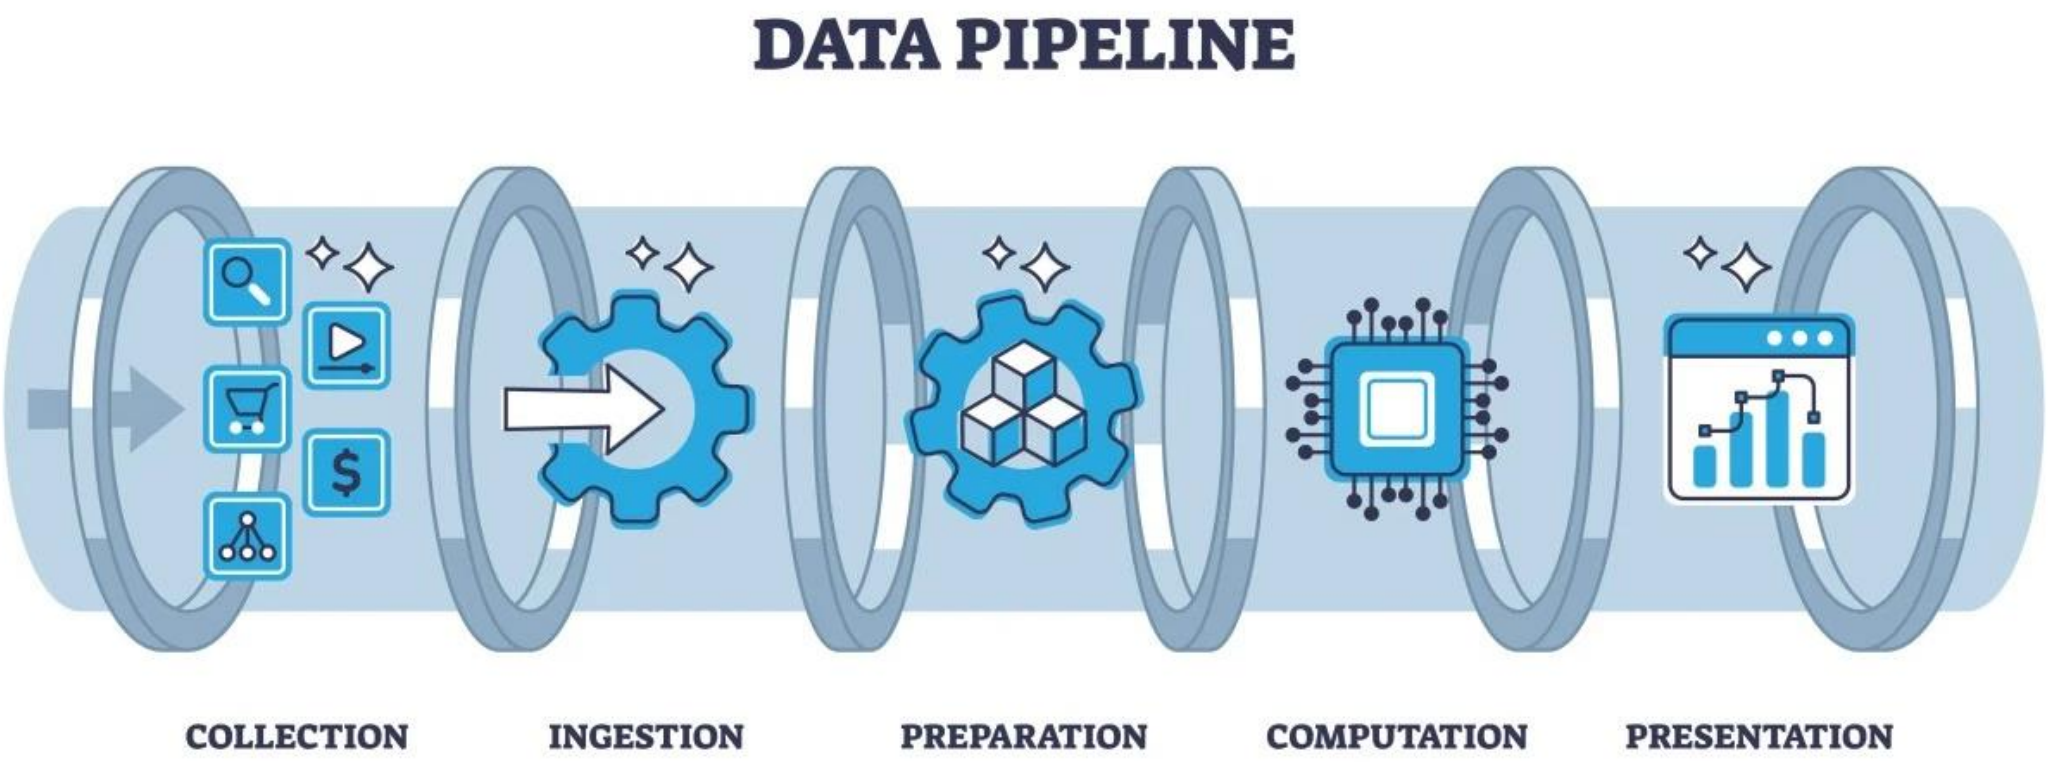

https://bit.ly/4qVkMRv

Pipeline dati e ETL

Extract Transform and Load

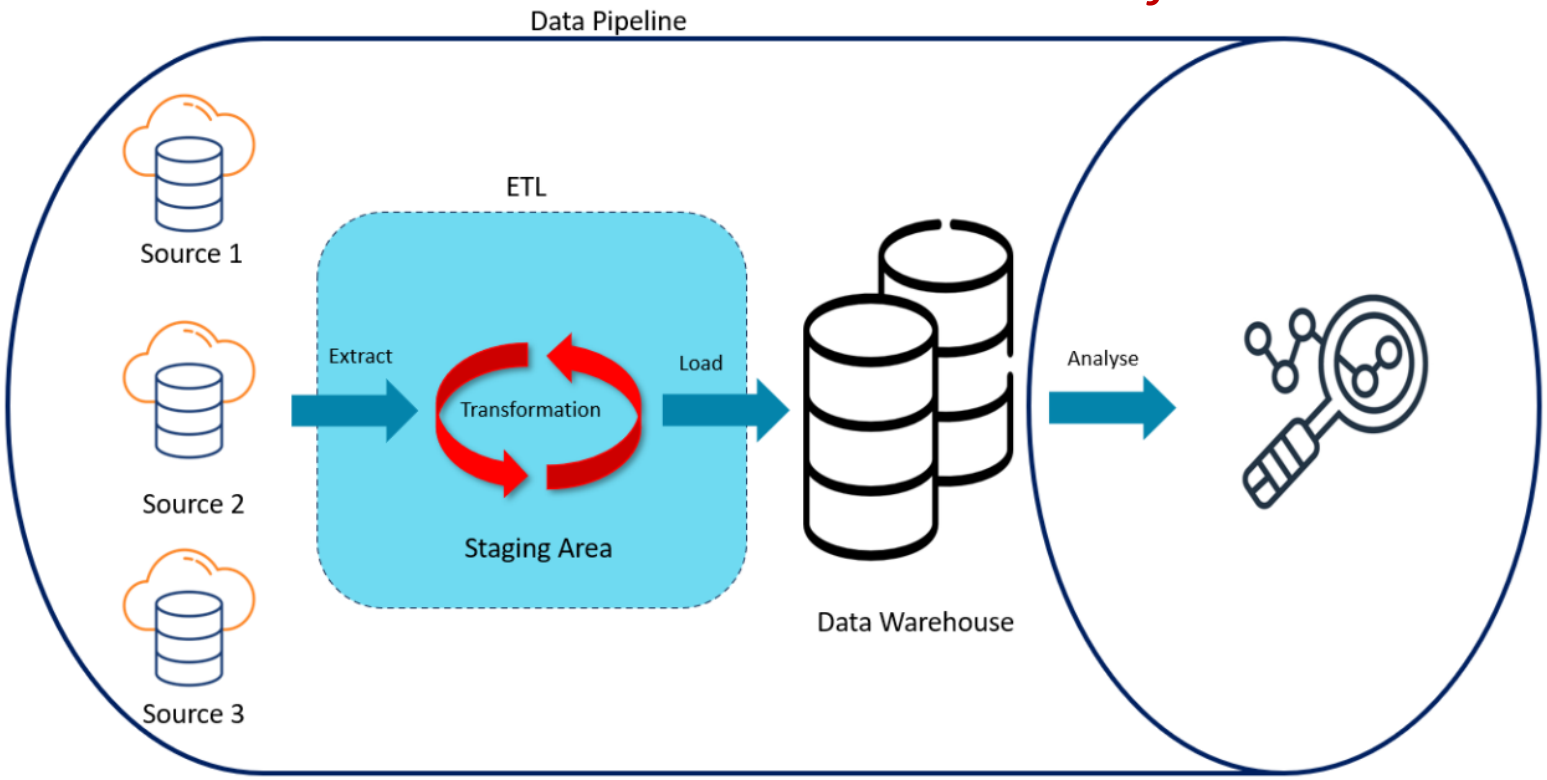

Pipeline dati e ETL

- Collection & Ingestion
  - I dati possono essere estratti da sorgenti eterogenee: sensori, log internet, corpora documentali, dati biomedici …
  - Problematiche di gestione di dati strutturati o parzialmente strutturati
  - Volume e velocità dei dati
    Big Data
  - Database, data warehouse, data lake, File System distribuiti, database NoSQL
    Big Data

Pipeline dati e ETL

- Preparation (Transformation)
  - Trasformazione dei dati grezzi in formati compatibili con gli algoritmi di analisi:
    - Vettori multidimensionali
    - Serie temporali
    - Dati binari o categorici
    - …

Pipeline dati e ETL

- Preparation (Transformation)
  - *Data cleaning*: gestione dei dati mancanti o erronei
    - Stima dei dati mancanti
    - Correzione degli errori
    - Riconciliazione dei dati tra sorgenti diverse
  - *Dipende dalla conoscenza sul problema!!*

Pipeline dati e ETL

- Preparation (Transformation)
  - *Feature selection*: Scegliere le feature più significative per il problema!!
  - Feature: *una qualunque proprietà valorizzabile del dato* (es. i campi di un record)
  - Insieme di tecniche statistiche o di Machine Learning per selezionare le feature che massimizzano la performance dell'algoritmo di analisi

Pipeline dati e ETL

- Preparation (Transformation)
  - I dati «curati» (feature significative, gestione degli errori e selezione del formato) sono di nuovo conservati nel data warehouse o comunque in una base di dati (non necessariamente relazionale)

Pipeline dati e ETL

- Computation (Analisi dei dati)
  - Si considerino i dati organizzati in un «database» $\mathcal{D}$ con *n* record e *d* attributi che può essere rappresentato da da una matrice di dati *X* composta da *n* vettori riga $\mathbf{x} \in \mathbb{R}^d$

Pipeline dati e ETL

- Computation (Analisi dei dati)
  - In senso molto generale possiamo ricercare:
  - Strutture ricorrenti tra le feature *all'interno di ogni singolo dato* che lo correlano con un'ulteriore feature che è l'obiettivo dell'analisi e che può non essere nota nel problema reale (relazioni tra le colonne di *X*)
  - Similarità *tra diverse istanze dei dati* che li rendono *più simili tra loro rispetto agli altri* secondo qualche criterio di analisi (relazioni tra le righe di *X*)

Tipologie generali di analisi dei dati

- Clustering
  - Ricerca di similarità tra i dati per l'individuazione di *gruppi* (cluster) tra di essi
  - *Apprendimento non supervisionato*: i gruppi sono non noti sia per numero sia per struttura nel data set disponibile per l'analisi

Tipologie generali di analisi dei dati

- Classificazione
  - Predizione di una *etichetta* (label) discreta da associare a ciascun dato per categorizzarlo in una *classe di appartenenza*

  - *Apprendimento supervisionato*: le etichette sono *note* per il data set disponibile per l'analisi, ma lo scopo dell'analisi è *predire* le etichette per nuovi dati in arrivo

Tipologie generali di analisi dei dati

- Outlier analysis
  - Il clustering può essere utilizzato in forma duale per individuare degli elementi anomali o *outlier* che non si armonizzano con i dati analizzati
  - Outlier: «Un'osservazione che devia così tanto dalle altre da sollevare il sospetto sia stata generata da un meccanismo differente»

Tipologie generali di analisi dei dati

- Outlier analysis
  - Intrusion detection
  - Rilevamento di frodi finanziarie o su carte di credito
  - Pattern anomali da rilevamento di sensori (prevenzione guasti)
  - Pattern inusuali nel medical imaging (malattie)
  - Previsioni meteo e ambientali
  - …

Tipologie generali di analisi dei dati

- Frequent pattern mining
  - Si assuma che i dati siano binari che *X* sia molto sparsa
    - Database delle transazioni commerciali ottenuti dagli scontrini
    - Ogni record è un acquisto: solo gli item acquistati valgono 1
  - Supporto supp(*P*) = *n. osservazioni di P / totale osservazioni*
  - Un pattern frequente *F* è tale che supp(*F*) $\geqslant$ *soglia minima*

Tipologie generali di analisi dei dati

- Frequent pattern mining
  - Regola di associazione *A* ⇒ *B*: associazione tra pattern frequenti che ha una certa *confidenza*:
    - Frazione delle righe contenenti *A*, che contiene anche *B* $\mathrm{conf}(A \Rightarrow B) = \frac{\mathrm{supp}(A \cup B)}{\mathrm{supp}(A)}$
  - Mining di regole di associazione con supporto minimo *s* e confidenza *c*:

$$\mathrm{supp}(A) \geqslant s$$

$$\mathrm{conf}(A \Rightarrow B) \geqslant c$$

Tipologie generali di analisi dei dati

- Esempio

- *supp*({*Eggs, Milk*}) = 3/5 = 0.6

- *conf*({*Eggs, Milk*} → {*Yogurt*}) = (2/5) / (3/5) = 2 / 3 = 0.666

tid	Set of items	Binary representation
1	$\{Bread, Butter, Milk\}$	110010
2	$\{Eggs, Milk, Yogurt\}$	000111
3	$\{Bread, Cheese, Eggs, Milk\}$	101110
4	$\{Eggs, Milk, Yogurt\}$	000111
5	$\{Cheese, Milk, Yogurt\}$	001011

X

Principali tipi di dati

- Dati interdipendenti e non interdipendenti
  - L'interdipendenza è legata alla natura del fenomeno descritto dai dati per cui le singole istanze dipendono tra di loro
    - Dipendenze *implicite* ed *esplicite*
    - Serie temporali (letture successive di sensori, parole in un testo …)
    - Grafi (social network analysis, database molecolari …)
    - Dati geospaziali
  - Dati non interdipendenti:
    - Dati multidimensionali conservati in un database

Dati non interdipendenti

- Dati multidimensionali

$$\mathcal{D} = \{\bar{X}_i,\ i = 1, \ldots, n : \bar{X}_i = (x_i^1, \ldots, x_i^d)\}$$

Name	**Age**	**Gender**	**Race**	**ZIP code**
John S.	45	M	African American	05139
Manyona L.	31	F	Native American	10598
Sayani A.	11	F	East Indian	10547
Jack M.	56	M	Caucasian	10562
Wei L.	63	M	Asian	90210

Dati non interdipendenti

- Dati multidimensionali

$$\mathcal{D} = \{\bar{X}_i,\ i = 1, \ldots, n : \bar{X}_i = (x_i^1, \ldots, x_i^d)\}$$

- X_i
  - Data point
  - Istanza
  - Esempio
  - Tupla
  - Oggetto
  - Record
  - Transazione
- x_i^k
  - Campo
  - Attributo
  - Dimensione
  - Feature

Dati non interdipendenti

- Dati numerici
- Dati categorici: assumono un insieme *discreto e non ordinato* di valori non necessariamente numerici
- Dati misti: numerici e categorici
- Binari: dati categorici a due valori o dati di appartenenza ad un insieme
- Stringhe

Dati interdipendenti

- Serie temporali (serie discrete)
  - Attributi contestuali: descrivono l'implicita interdipendenza tra i dati
    - Time stamp
    - Indice di posizione

$$(t_1; \bar{Y}_1), (t_2; \bar{Y}_2), \ldots, (t_n; \bar{Y}_n)$$

$$\bar{Y}_i = \left(y_i^1 \ldots y_i^d\right)$$

  - Attributi comportamentali: descrivono l'effettivo contenuto informativo della serie

  - In genere si tratta di dati multivariati continui o discreti
    - Sequenze discrete: stringhe, sequenze proteiche, dati di log …

Dati interdipendenti

- Dati spaziali
  - Simili alle serie temporali: la marca è una geolocalizzazione L_i

$$(L_1; \bar{X}_1), (L_2; \bar{X}_2), \ldots, (L_n; \bar{X}_n)$$
$$\bar{X}_i = \left(x_i^1 \ldots x_i^d\right)$$

  - Si possono cercare regolarità su dati legati a marche spaziali adiacenti

Dati interdipendenti

- Dati a grafo
  - I dati sono esplicitamente organizzati secondo un grafo

$$G = (V, E)$$

$$\forall v_i \in V,\ v_i \mapsto \bar{X}_i$$

$$\forall e_{i,j} \in E,\ e_{i,j} \mapsto \bar{Y}_{i,j}$$

Dati interdipendenti

- Dati testuali
  - Singoli caratteri
  - Singole parole
  - N- grammi
  - Embedding
    - Word frequency
    - TF-IDF
    - Neural embedding

Dati interdipendenti

- Dati testuali: N-grammi

- Un *Language Model* esprime, rispetto ad un testo, la sua probabilità $P(W) = P(w_1,w_2,w_3,w_4,w_5 \ldots w_n)$ ovvero $P(W) = P(w_n | w_1,w_2 \ldots w_{n-1})$

- Come calcolarla? La Chain Rule della Probabilità

Dati interdipendenti

- Dati testuali: N-grammi

$$P(w_1 w_2 \ldots w_n) = \prod_i P(w_i \mid w_1 w_2 \ldots w_{i-1})$$

P("its water is so transparent that") =

P(its) × P(water|its) × P(is|its water)

× P(so|its water is) × P(transparent|its water is so)

× P(that | its water is so transparent)

Dati interdipendenti

- Come calcoliamo queste probabilità?

$$P(\text{the} \mid \text{its water is so transparent that}) = \frac{Count(\text{its water is so transparent that the})}{Count(\text{its water is so transparent that})}$$

- No! Troppe frasi possibili!
- Non abbiamo abbastanza dati

Dati Interdipendenti

Andrei Markov

- Dati testuali: N-grammi

- Usiamo l'assunzione di Markov

$$P(\text{the} \mid \text{its water is so transparent that}) \approx P(\text{the} \mid \text{that})$$

«that the» → bi-gramma

- O magari

$$P(\text{the} \mid \text{its water is so transparent that}) \approx P(\text{the} \mid \text{transparent that})$$

«transparent that the» → tri-gramma

Dati interdipendenti

- Dati testuali: neural embedding
  - Rappresentazioni vettoriali delle parole in un testo in cui si cerca di catturare la dipendenza di una parola dalle altre
  - Ottenuti attraverso reti neurali
  - Embedding non contestuali: associazione univoca parola ←→ vettore
  - Embedding contestuali: si ottengono dall'addestramento di *Large Language Model* dedicati in cui si cerca di massimizzare la creazione di vettori distinti per ciascun significato di una parola

Dati interdipendenti

- Dati testuali: neural embedding

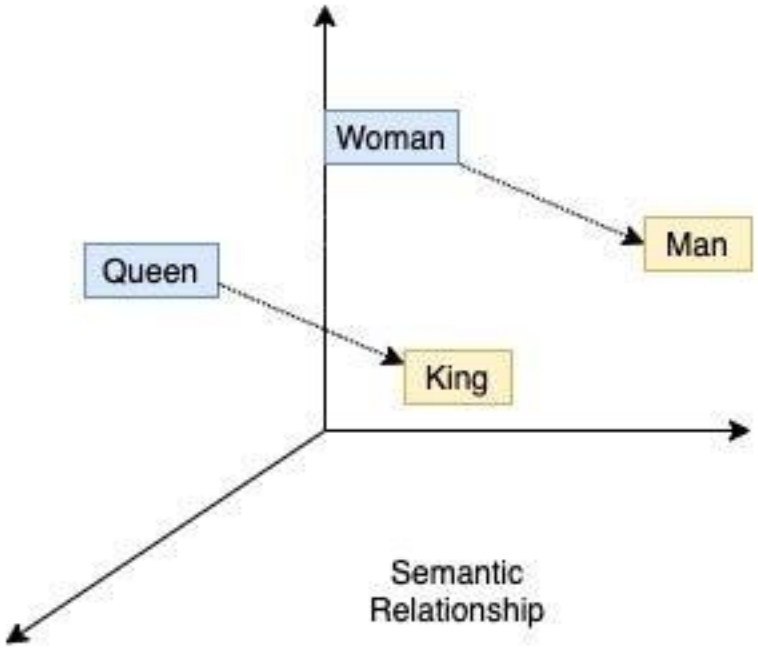

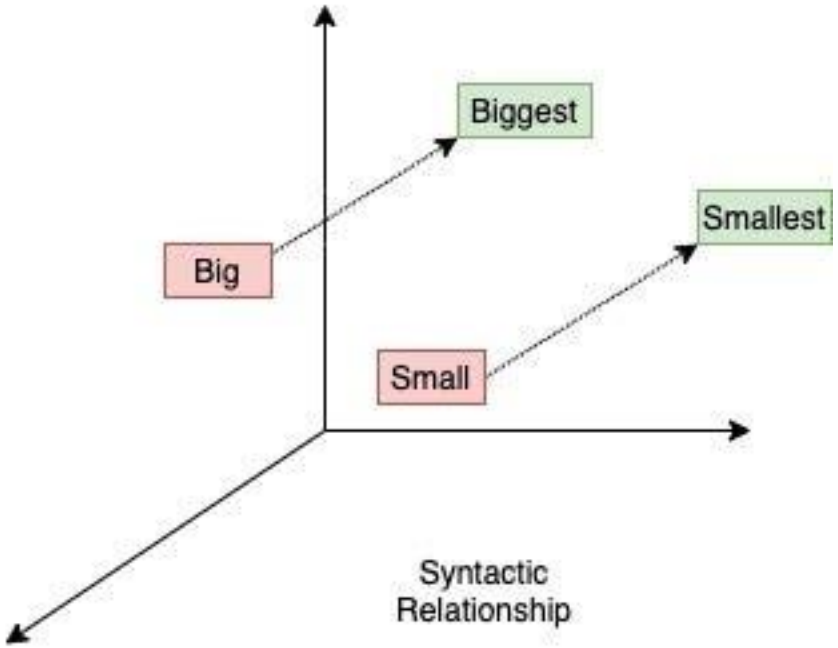

https://bit.ly/3M1IYTj

Dati interdipendenti

- Dati testuali: neural embedding