Università degli Studi di Palermo

dipartimento di ingegneria unipa

Preprocessing dei Dati

MASTER DI II LIVELLO - DIGITALIZZAZIONE DEL SISTEMA ELETTRICO PER LA TRANSIZIONE ENERGETICA

MODULO 5 – GESTIONE DEI DATI E DELLE INFORMAZIONI

a.a. 2025/2026

Prof. Roberto Pirrone

LABORATORIO DI INTERAZIONE UOMO-MACCHINA
CHILAB

Sommario

- Data preparation
- Data cleaning
- Portabilità tra diverse tipologie di dati
- Riduzione della dimensionalità dei dati

Data preparation

- Data cleaning
  - Eliminazione di dati erronei e/o inconsistenti
  - *Imputazione* dei dati mancanti attraverso un processo di stima

Data preparation

- Estrazione delle feature e portabilità
  - Si ricercano le feature più significative in relazione al problema da risolvere
  - feature vanno *convertite nelle tipologie di dati* più adatte per l'utilizzo con gli algoritmi di analisi

Data preparation

- Data reduction & transformation
  - Riduzione del volume dei dati tramite *campionamento* di un sotto insieme, *riduzione della dimensionalità* dei campioni ovvero *trasformazione* degli stessi secondo una diversa rappresentazione

Data cleaning

- Gestione dei dati mancanti
  - Eliminazione dei record incompleti se troppo sparsi
  - Stima o imputazione dei dati mancanti
    - Su basi statistiche oppure «informata»
  - Uso di algoritmi di analisi robusti rispetto ai dati mancanti
    - Classificazione dei campioni completi rispetto alla feature mancante e imputazione tramite inferenza

Data cleaning

- Gestione dei dati mancanti

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			5		2
U_2		5			4	
U_3	5	3		1		
U_4			3			4
U_5				3	5	
U_6	5		4			

(a) Ratings-based utility

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			1		1
U_2		1			1	
U_3	1	1		1		
U_4			1			1
U_5				1	1	
U_6	1		1			

(b) Positive-preference utility

Recommender Systems

I Sistemi di Raccomandazione (Google, Amazon, …) utilizzano la *utility matrix* per gestire i rating degli utenti rispetto a degli item (prodotti, film, libri …)

Possiamo pensare agli utenti come «vettori di item» ovvero agli item come «vettori di utenti»

Data cleaning

- Gestione dei dati mancanti

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			5		2
U_2		5			4	
U_3	5	3		1		
U_4			3			4
U_5				3	5	
U_6	5		4			

(a) Ratings-based utility

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			1		1
U_2		1			1	
U_3	1	1		1		
U_4			1			1
U_5				1	1	
U_6	1		1			

(b) Positive-preference utility

Collaborative filtering

La utility matrix è sempre molto sparsa.

Stima dei dati mancanti (preferenze di un utente ovvero item con preferenze simili degli utenti) calcolando *funzioni di similarità* tra le righe o le colonne.

I *k* utenti/item più simili vengono usati per imputare i valori

Data cleaning

- Eliminazione dei dati inconsistenti o erronei
  - Analisi di dati inconsistenti tra flussi in arrivo da sorgenti diverse
    - Es. «John Fitzgerald Kennedy» vs. «JFK»
  - Uso della conoscenza di dominio per eliminare le inconsistenze
  - Analisi statistica dei dati per individuare il trend ovvero esplicito utilizzo di algoritmi di *outlier detection*

Data cleaning

- Outlier detection
  - Calcolo di media, deviazione standard, minimo, massimo e tracciamento del box plot per eliminare gli outlier per ispezione diretta
  - Eliminazione delle code (*tails*: oltre i ±3σ) dei dati numerici supposti gaussiani
  - Tecniche di individuazione dei punti isolati nel data set, in genere basate sul calcolo dei *k*-vicini di ogni punto, oppure algoritmi di clustering che individuano esplicitamente i punti isolati

Data cleaning

- Scalatura e normalizzazione
  - Scalatura min-max

$$y_i^j = \frac{x_i^j - \min_j}{\max_j - \min_j}$$

  - Z-scaling

$$z_i^j = \frac{x_i^j - \mu_j}{\sigma_j}$$

Portabilità tra tipologie di dati

- Spesso è conveniente trasformare il dato dal suo formato nativo ad uno più adatto all'utilizzo degli algoritmi di analisi statistica o di Machine Learning

- Numerico → Categorico: Discretizzazione
- Categorico → Numerico: one-hot encoding
- Serie temporale → Serie discreta: SAX

Portabilità tra tipologie di dati

- Spesso è conveniente trasformare il dato dal suo formato nativo ad uno più adatto all'utilizzo degli algoritmi di analisi statistica o di Machine Learning

- Serie temporale → Numerico: Trasformate
- Grafo → Numerico: MDS
- Qualunque tipo → Grafo: Grafi di similarità

Portabilità tra tipologie di dati

- Discretizzazione
  - Si creano degli intervalli discreti per rappresentare il range di variazione del dato numerico
    - Intervalli ad ampiezza costante
    - Intervalli logaritmici: ogni intervallo $[a,b]$ → $\log(b) - \log(a)$ = costante
    - Intervalli equiprobabili $[a,b]$ → $P(x \in [a,b])$ = costante per una certa distribuzione di probabilità dei dati $p(x)$
    - Intervalli a «profondità» costante: ogni intervallo contiene lo stesso numero di elementi

Portabilità tra tipologie di dati

- One-hot encoding
  - Ogni categoria possibile induce la creazione di un *one-hot vector* i cui componenti sono tutti nulli tranne quello in posizione corrispondente alla categoria

$$a \in \{c_1, c_2, \ldots, c_\phi\} \rightarrow \mathbf{x} \in \mathbb{R}^\phi,$$
$$a = c_k \rightarrow \mathbf{x} = [0_1, 0_2, \ldots, 1_k, \ldots, 0_\phi]$$

Portabilità tra tipologie di dati

- Symbolic Aggregate Approximation (SAX)
  - Si effettua la media dei valori della serie temporale su finestre di osservazione contigue di data ampiezza *w*
  - Si discretizza la serie numerica risultante con intervalli a profondità costante, assumendo che sia gaussiana e considerando i quantili
  - Il risultato è una serie discreta di simboli

Portabilità tra tipologie di dati

- Trasformate
  - Discrete Wavelet Transform (DWT) e Discrete Fourier Transform (DFT)
  - Una sequenza temporale discreta **x** ={*x*[0], *x*[1], …, *x*[*N*-1]} viene trasformata in un vettore multidimensionale **X** attraverso una *base di funzioni* che esprimono frequenze (DFT) o scale spaziali (DWT)

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot \psi_k[n]$$

Portabilità tra tipologie di dati

- Trasformate
  - Discrete Wavelet Transform (DWT) e Discrete Fourier Transform (DFT)
  - Riduzione di dimensionalità e omogeneizzazione tra serie di lunghezza diversa

$$\mathbf{X} = \mathbf{W} \cdot \mathbf{x} \qquad W_{k,n} = \psi_k[n]$$

Portabilità tra tipologie di dati

- Multidimensional Scaling (MDS)
  - Funziona per grafi pesati in cui il peso di ogni arco sia δ_{ij}
  - Si assuma di voler rappresentare ogni nodo $i = 1, \ldots, n$ con un embedding k-dimensionale $X_i \in \mathbb{R}^k$ per esempio bi- o tri-dimensionale
  - Assumendo di conoscere tutte i pesi $\delta_{ij} = \delta_{ji}$, si minimizza il seguente funzionale

$$O = \sum_{i,j:i<j} \left(\|\overline{X_i} - \overline{X_j}\| - \delta_{ij} \right)^2$$

Portabilità tra tipologie di dati

- Generazione di grafi di similarità
  - Ricerca di similarità tra coppie di dati
  - Ogni oggetto O_i del data set è rappresentato come un nodo multidimensionale di un grafo
  - Se $d(O_i,O_j) < \epsilon$, soglia prestabilita, si genera un arco (i,j) con peso w_{ij} generato applicando un opportuno kernel che esprime *similarità*

$$w_{ij} = e^{-\frac{d(O_i,O_j)^2}{t^2}}$$

Heat kernel

Riduzione della dimensionalità dei dati

- Campionamento
- Selezione di sottoinsiemi di feature rilevanti (*feature selection*)
- Riduzione della dimensionalità per *rotazione degli assi*

Riduzione della dimensionalità dei dati

- Campionamento
  - La dimensionalità di un data set $\mathcal{D}$, già curato, sul quale addestriamo un algoritmo di apprendimento, può essere variata per *sottocampionamento* o anche per *sovracampionamento*

Riduzione della dimensionalità dei dati

- Campionamento
  - Queste tecniche si applicano ai classificatori in cui gli esempi appartenenti alle varie classi sono fortemente *sbilanciati* ovvero una o più classi sono fortemente più numerose delle altre
  - *Sottocampionamento* → riduco i campioni delle classi più popolose
  - *Sovracampionamento* → accresco «sinteticamente» i campioni delle classi meno popolose

Riduzione della dimensionalità dei dati

- Campionamento
  - Campionamento con rimpiazzo o senza rimpiazzo
  - Campionamento «stratificato»: si ricopre il dominio della variabile con una serie di intervalli o *strati.* Si campiona ogni strato in proporzione alla popolazione di dati in esso presente.
  - Campionamento «per importanza»: alcune parti dei dati sono certamente più rilevanti di altre e quindi si ha a disposizione una distribuzione $p(x)$ che descrive la *probabilità di campionare* un certo valore x.

Riduzione della dimensionalità dei dati

- Selezione di sottoinsiemi di feature rilevanti
  - Tramite calcolo di appositi «score» sulle singole feature
  - Tramite algoritmo di Machine Learning (classificazione o clustering a seconda dei fini dell'analisi)
    - L'algoritmo di ML viene applicato a sottoinsiemi di feature differenti
    - Si seleziona il sottoinsieme per le quali l'algoritmo fornisce la performance più alta

Riduzione della dimensionalità dei dati

- Riduzione della dimensionalità per rotazione degli assi
  - Dati altamente correlati si aggregano lungo *poche direzioni preferenziali* che possono diventare gli *assi di un apposito sistema di riferimento* ottenuto per rotazione

Riduzione della dimensionalità per rotazione degli assi – caso gaussiano

- Distribuzione gaussiana

  o «Normale»

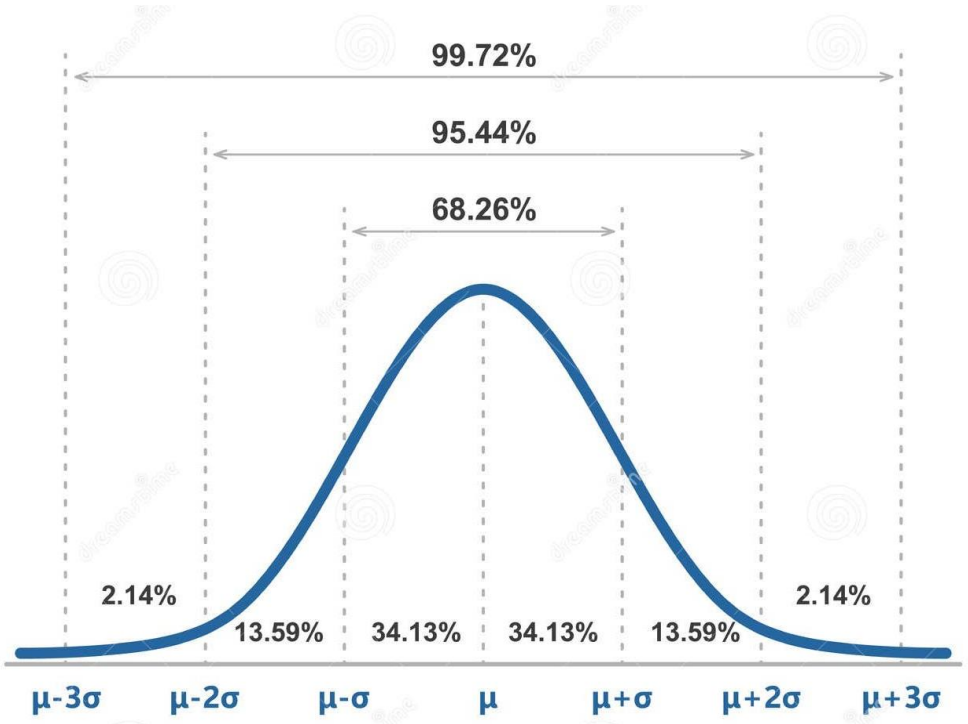

$$\mathcal{N}\left(x;\mu,\sigma^2\right) = \sqrt{\frac{1}{2\pi\sigma^2}}\exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$$

Riduzione della dimensionalità per rotazione degli assi – caso gaussiano

- Distribuzione gaussiana

  o «Normale» multivariata

  $\mathbf{x} \in \mathbb{R}^n$

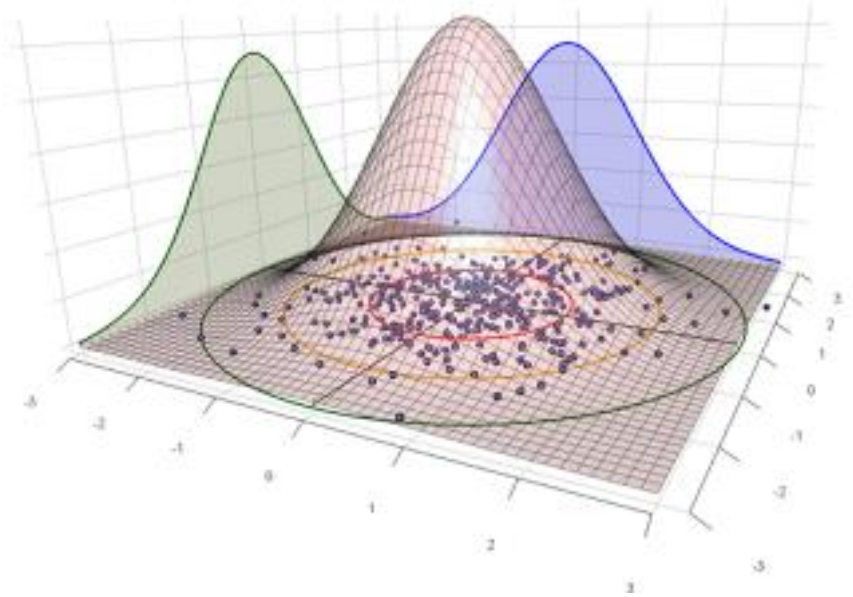

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sqrt{\frac{1}{(2\pi)^n \det(\boldsymbol{\Sigma})}} \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})\right)$$

*$\boldsymbol{\Sigma}$ è la matrice di covarianza di **x***

Riduzione della dimensionalità per rotazione degli assi – caso gaussiano

$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

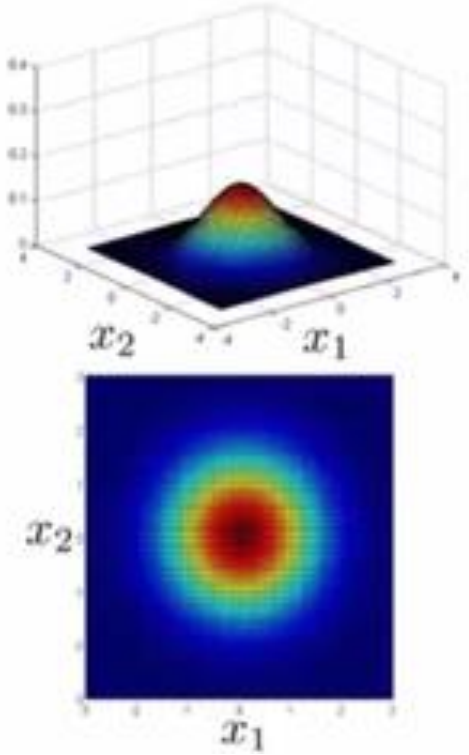

$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Sigma = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix}$$

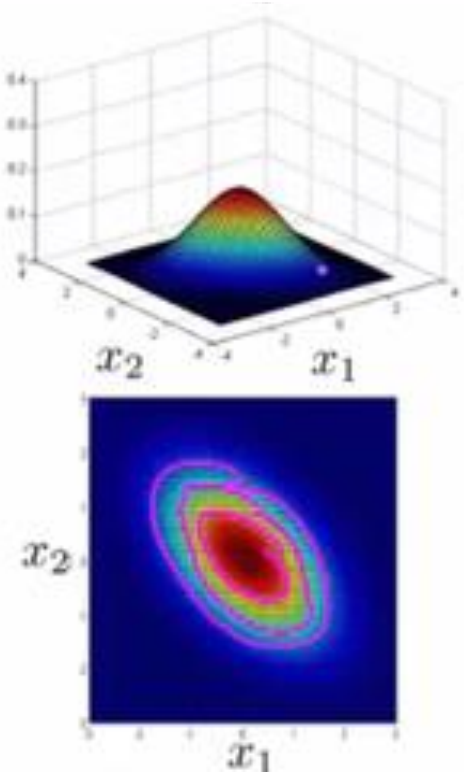

$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Sigma = \begin{bmatrix} 1 & -0.8 \\ -0.8 & 1 \end{bmatrix}$$

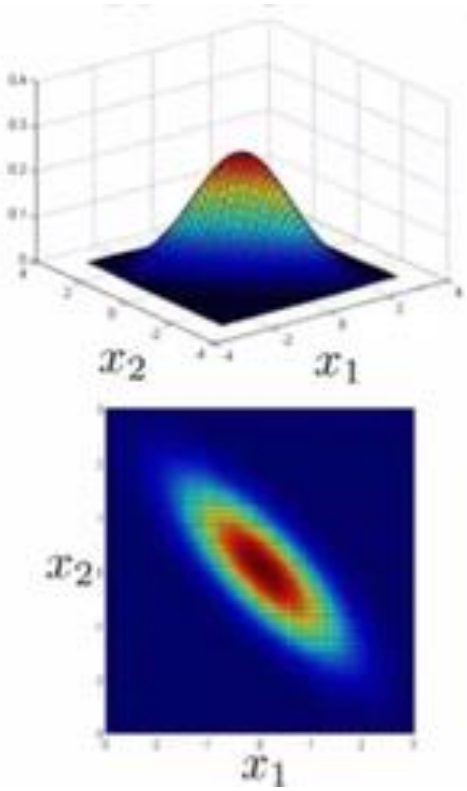
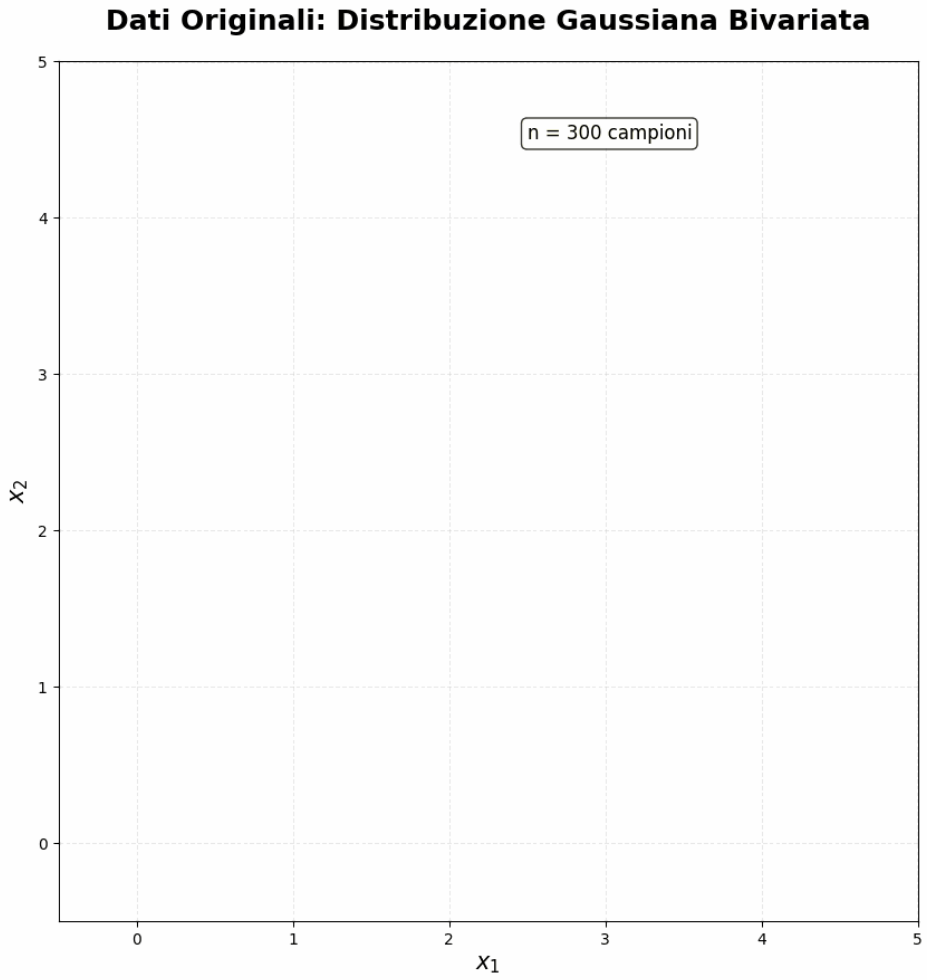
Riduzione della dimensionalità per rotazione degli assi – Principal Component Anaysis